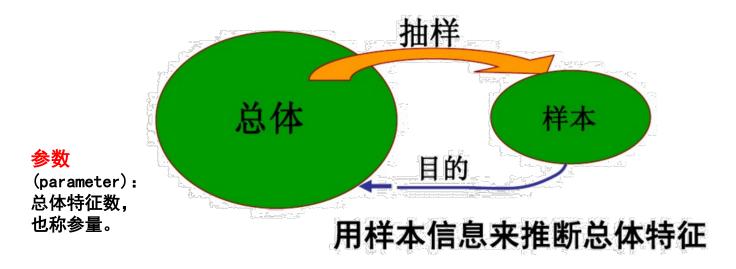
第5章 参数估计

李镇清

中国科学院大学

统计学基本问题:

研究总体与样本的关系



样本统计量推断总体参数,以抽样分布为基础统计推断:假设检验,参数估计

统计量

(staistic): 样本特征数,也称统的数,由样本算出的量,或者说统计量就是样本的函数。统计量只依赖于量只依赖于任何未知的量有关。

抽样分布: 样本统 计量的分布

参数的区间估计与点估计

一、参数区间估计与点估计的原理

- 二、总体平均数的区间估计与点估计
- 三、两个总体平均数差数的区间估计与点估计

参数估计(parameter estimation)

参数估计(parameter estimation),统计推断的一种。根据从总体中抽取的随机样本来估计总体分布中未知参数的过程。从估计形式看,区分为点估计与区间估计;从构造估计量的方法讲,有矩法估计、最小二乘估计、似然估计、贝叶斯估计等。

要处理两个问题:

- (1) 求出未知参数的估计量;
- (2) 在一定置信度(可靠程度)下指出所求的估计量的精度。信度一般用概率表示,如置信程度为95%;精度用估计量与被估参数(或待估参数)之间的接近程度或误差来度量。

用估计量估计总体参数

- 估计量是估计总体参数的统计量,两种估计,一种是点估计(point estimation),即用估计量的实现值来近似相应的总体参数。
- 另一种是区间估计(interval estimation);它是包括估计量在内(有时是以估计量为中心)的一个区间;该区间被认为很可能包含总体参数。
- 点估计给出一个数字,用起来很方便;而区间估计给出一个区间,说起来留有余地;不像点估计那么绝对。

点估计

最常用的估计量: 样本均值、样本标准差(s)和(Bernoulli试验的)成功比例(x/n);
用它们来分别估计总体均值(μ)、总体标准差(σ)和成功概率(或总体中的比例)p.

点估计

用什么样的估计量来估计参数呢?

- 衡量一个估计量好坏的标准。每个标准一般都仅反映估计量 的某个方面。
- 这样就出现了按照这些标准定义的各种名目的估计量(如无偏估计量等)。
- 另一些估计量则是由它们的计算方式来命名的(如最大似然 估计和矩估计等)。

好估计量的标准

(1) 无偏性

无偏性是指估计量抽样分布的数学期望等于总体参数的真值。无偏性的含义是,估计量是一随机变量,对于样本的每一次实现,由估计量算出的估计值有时可能偏高,有时可能偏低,但这些估计值平均起来等于总体参数的真值。在平均意义下,无偏性表示没有系统误差。

(2) 有效性

有效性是指估计量与总体参数的离散程度。如果两个估计量都是无偏的, 那么离散程度较小的估计量相对而言是较为有效的。离散程度是用方差 度量的,因此在无偏估计量中,方差愈小愈有效。

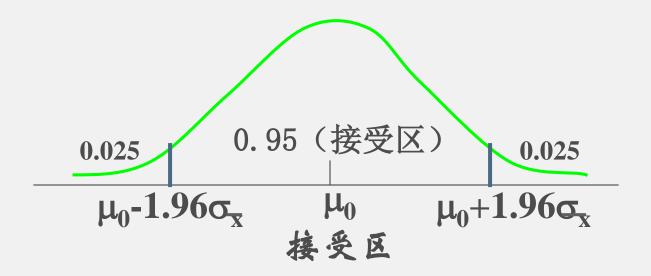
(3) 一致性

一致性,又称相合性,是指随着样本容量的增大,估计量愈来愈接近总体参数的真值

一、参数区间估计与点估计的原理

参数的区间估计与点估计是建立在一定理论基础上的一种方法。

由中心极限定理和大数定律,只要抽样为大样本,不论其总体是否为正态分布,其样本平均数都近似服从正态分布 $N(\mu, \sigma^2/n)$ 。





长格界值
$$\mu \pm u_{\alpha/2}\sigma_x$$

$$P(\mu - 1.96\sigma_{\bar{x}} < \bar{x} < \mu + 1.96\sigma_{\bar{x}}) = 0.95$$

$$P(\bar{x} > \mu + 1.96\sigma_{\bar{x}}) + P(\bar{x} > \mu - 1.96\sigma_{\bar{x}}) = 0.05$$

$$P(\mu - 2.58\sigma_{\bar{x}} < \bar{x} < \mu + 2.58\sigma_{\bar{x}}) = 0.99$$

$$P(x > \mu + 2.58\sigma_{\bar{x}}) + P(x > \mu - 2.58\sigma_{\bar{x}}) = 0.01$$

$$P(\mu - 1.96\sigma_{\bar{x}} < \bar{x} < \mu + 1.96\sigma_{\bar{x}}) = 0.95$$

$$P(-1.96\sigma_{\bar{x}} < \bar{x} - \mu < 1.96\sigma_{\bar{x}}) = 0.95$$

$$P(-\bar{x}-1.96\sigma_{\bar{x}} < -\mu < -\bar{x}+1.96\sigma_{\bar{x}}) = 0.95$$

$$P(\bar{x}+1.96\sigma_{\bar{x}} > \mu > \bar{x}-1.96\sigma_{\bar{x}}) = 0.95$$

$$P(\bar{x}-1.96\sigma_{\bar{x}} < \mu < \bar{x}+1.96\sigma_{\bar{x}}) = 0.95$$

$$P(\mu - 2.58\sigma_{\bar{x}} < \bar{x} < \mu + 2.58\sigma_{\bar{x}}) = 0.99$$

$$P(x - 2.58\sigma_{\bar{x}} < \mu < x + 2.58\sigma_{\bar{x}}) = 0.99$$

$$P(\bar{x}-1.96\sigma_{\bar{x}} < \mu < \bar{x}+1.96\sigma_{\bar{x}}) = 0.95$$

$$P(\bar{x} - 2.58\sigma_{\bar{x}} < \mu < \bar{x} + 2.58\sigma_{\bar{x}}) = 0.99$$

$$P(\overline{x} \quad u_{\alpha/2}\sigma_{\overline{x}} < \mu < \overline{x} + u_{\alpha/2}\sigma_{\overline{x}}) = 1 - \alpha$$

 u_{α} : 正态分布下置信度P=1- α 时的u临界值

α: 置信水平

$$P(\overline{x} - u_{\alpha/2}\sigma_{\overline{x}} < \mu < \overline{x} + u_{\alpha/2}\sigma_{\overline{x}}) = 1 - \alpha$$

知道 \bar{x} ,但不知道 μ

1- α置信区间、置信距
$$(x - u_{\alpha/2}\sigma_{\overline{x}}, x + u_{\alpha/2}\sigma_{\overline{x}})$$

$$(L_1 = \bar{x} - u_{\alpha/2} \sigma_{\bar{x}}, L_2 = \bar{x} + u_{\alpha/2} \sigma_{\bar{x}})$$

$$(L_1 = \overline{x} - u_{\alpha/2} \sigma_{\overline{x}}, L_2 = \overline{x} + u_{\alpha/2} \sigma_{\overline{x}})$$

用样本平均数 \bar{x} 对总体平均数 μ 的置信度为 $P=1-\alpha$ 的区间估计。

$$L = \bar{x} \pm u_{\alpha/2} \sigma_{\bar{x}}$$

用样本平均数 \bar{x} 对总体平均数 μ 的置信度为 $P=1-\alpha$ 的点估计。

二、总体平均数µ的区间估计和点估计

当为大样本时,不论总体方差σ²为已知或未知,可以利用样本平均数x和总体方差σ²作出置信度为P=1-α的中体平均数的区间估计为:

$$(L_1 = \overline{x} - u_{\alpha/2}\sigma_{\overline{x}}, L_2 = \overline{x} + u_{\alpha/2}\sigma_{\overline{x}})$$

其置信区间的下限L₁和上限L₂为

$$L_1 = \overline{x} - u_{\alpha/2} \sigma_{\overline{x}}$$

$$L_2 = \overline{x} + u_{\alpha/2} \sigma_{\overline{x}}$$

总体平均数的点估计L为

$$L = \overline{x} + u_{\alpha/2} \sigma_{\overline{x}}$$

当样本为小样本且总体方差σ²未知时, σ²需由样本方差s²来估计,于是置信度为P= 1-α的总体平均数μ的置信区间可估计为

$$(\overline{x}-t_{\alpha/2}s_{\overline{x}},\overline{x}+t_{\alpha/2}s_{\overline{x}})$$

其置信区间的下限L₁和上限L₂为:

$$(L_1 = \overline{x} - t_{\alpha/2} s_{\overline{x}}, L_2 = \overline{x} + t_{\alpha/2} s_{\overline{x}})$$

总体平均数的点估计L为:

$$L = x + t_{\alpha/2} s_{\bar{x}}$$

 T_a 为正态分布下置信度 $P=1-\alpha$ 时的t临界值

例4.14测得某批25个小麦样本的平均蛋白质含量=14.5%,已知 σ = 2.50%,试进行95%置信度下的蛋白质含量的区间估计和点估计。

分析:本例 σ 为已知,置信度 $P=1-\alpha=0.95$,

 $u_{0.05} = 1.96$.

$$\sigma_{\bar{x}} = \frac{\sigma}{\sqrt{n}} = \frac{2.50}{\sqrt{25}} = 0.50$$

$$L_1 = \overline{x} - u_{\alpha/2} \sigma_{\overline{x}} = 14.5 \quad 1.96 \times 0.50 = 13.52(\%)$$

$$L_2 = x + u_{\alpha/2}\sigma_{\bar{x}} = 14.5 + 1.96 \times 0.50 = 15.48(\%)$$

蛋白质含量的点估计为:

$$L = \bar{x} \pm u_{\alpha/2} \sigma_{\bar{x}} = 14.5 \pm 1.96 \times 0.50 = 14.5 \pm 0.98$$

说明小麦蛋白质含量有95%的把握落在13.52%~15.48%的区间里。

例题 从某渔场收对虾的总体中,随机取20尾对虾,测的平均体长x=120mm,标准差是=15mm,试估计置信度为99%的对虾总体平均数

本例中,由于总体方差 σ^2 未知,需用 s^2 估计 σ^{2} 当 df = 20 - 1 = 19 时, $t_{0.01/2} = 2.861$ 。具体 计算如下

$$s_{\overline{x}} = \frac{s}{\sqrt{n}} = \frac{15}{\sqrt{20}} = 3.354$$

于是对虾体长的区间估计为

$$L_1 = \bar{x} - t_{\alpha/2} s_{\bar{x}} = 120 - 2.861 \times 3.354 = 110.4 (mm)$$

$$L_2 = \bar{x} + t_{\alpha/2} s_{\bar{x}} = 120 + 2.861 \times 3.354 = 129.6 (mm)$$

对虾体长的点估计为:

$$L = x \pm t_{\alpha/2} s_{\overline{x}}$$
= 120 \pm 2.861 \times 3.354 = 120 \pm 9.6(mm)

说明对虾体长有99%把握落在110.4mm~129.6mm 区间里

三、两个总体平均数差数 µ₁-µ₂的区间估计与点估计

当两个总体方差 σ_1^2 和 σ_2^2 为已知,或总体方差 σ_1^2 和 σ_2^2 未知但为大样本时,在置信度为P=1- α 下,两个总体平均数差数 μ_1 - μ_2 的区间估计为:

$$\begin{bmatrix} \overline{x_1} & \overline{x_2} \end{bmatrix} - u_{\alpha/2} \sigma_{\overline{x_1}} \frac{1}{x_2}, (\overline{x_1} & \overline{x_2}) + u_{\alpha/2} \sigma_{\overline{x_1}} \frac{1}{x_2} \end{bmatrix}$$

其置信区间的下限L₁和上限L₂为:

$$L_1 = (\overline{x_1} - \overline{x_2}) - u_{\alpha/2} \sigma_{\overline{x_1} - \overline{x_2}}, L_2 = (\overline{x_1} - \overline{x_2}) + u_{\alpha/2} \sigma_{\overline{x_1} - \overline{x_2}}$$

两个总体平均数差数此一此2的点估计L为

$$L = \left(\overline{x_1} - \overline{x_2}\right) \pm u_{\alpha/2} \sigma_{\overline{x_1} - \overline{x_2}}$$

当两个样本为小样本,总体方差 σ_1^2 和 σ_2^2 未知,当两总体方差相等,即 $\sigma_1^2 = \sigma_2^2$ = σ^2 时,可由两样本方差 s_1^2 和 s_2^2 估计总体方差 σ_1^2 和 σ_2^2 ,在置信度为P=1- α 下,两总体平均数差数 μ_1 - μ_2 的区间估计为:

$$\left[\left(\overline{x_{1}} - \overline{x_{2}}\right) - t_{\alpha/2} s_{\overline{x_{1}} - \overline{x_{2}}}, \left(\overline{x_{1}} - \overline{x_{2}}\right) + t_{\alpha/2} s_{\overline{x_{1}} - \overline{x_{2}}}\right]$$

其置信区间的下限L₁和上限L₂为:

$$L_1 = (\overline{x_1} - \overline{x_2}) - t_{\alpha/2} s_{\overline{x_1} - \overline{x_2}}, L_2 = (\overline{x_1} - \overline{x_2}) + t_{\alpha/2} s_{\overline{x_1} - \overline{x_2}}$$

两个总体平均数差数此一此的点估计上为:

$$L = \left(\overline{x_1} - \overline{x_2}\right) \pm t_{\alpha/2} s_{\overline{x_1}} \frac{1}{x_2}$$

当两个样本为小样本,总体方差 σ_1^2 和 σ_2^2 未知,且两总体方差不相等,即 $\sigma_1^2 \neq \sigma_2^2$ 时,可由两样本方差 s_1^2 和 s_2^2 对总体方差 σ_1^2 和 σ_2^2 的估计而算出的t值,已不是自由度df=n1+n2-2的t分布,而是近似的服从自由度df'的t分布,在置信度为P=1- α 下,两总体平均数差数 μ_1 - μ_2 的区间估计为:

$$(x_1 \ x_2) \ t_{\alpha/2(df')} s_{\overline{x_1}} - (x_1 \ x_2) + t_{\alpha/2(df')} s_{\overline{x_1}} - (x_2)$$

其置信区间的下限L1和上限L2为:

$$L_1 = (\overline{x_1} - \overline{x_2}) \quad t_{\alpha/2(df')} s_{\overline{x_1}} s_{\overline{x_2}}, L_2 = (\overline{x_1} - \overline{x_2}) + t_{\alpha/2(df')} s_{\overline{x_1} - \overline{x_2}}$$

两个总体平均数差数μ1-μ2的点估计 L为:

$$L = \left(\overline{x_1} - \overline{x_2}\right) \pm t_{\alpha, df} \cdot s_{\overline{x_1} - \overline{x_2}}$$

上面三式中, $t_{\alpha/2, df}$ 为置信度为 $P=1-\alpha$ 时自由度为df的t临界值。

当两样本为成对资料时,在置信度为 $P=1-\alpha$ 时,两总体平均数差数 μ_1 - μ_2 的置信区间可估计为:

$$\left(\overline{d} - t_{\alpha/2} s_{\overline{d}}, \overline{d} + t_{\alpha/2} s_{\overline{d}}\right)$$

其置信区间的下限L1和上限L2为:

$$(L_1 = \overline{d} - t_{\alpha/2} s_{\overline{d}}, L_2 = \overline{d} + t_{\alpha/2} s_{\overline{d}})$$

两个总体平均数差数μ1-μ2的点估计 L为:

$$L = \overline{d} \pm t_{\alpha/2} s_{\overline{d}}$$

例题 用高蛋白和低蛋白两种饲料饲养一月龄大白鼠,在三个月时,测定两组大白鼠的增重重量(g),两组的数据分别为:高蛋白组:134,146,106,119,124,161,107,83,113,129,97,123低蛋白组:70,118,101,85,107,132,94

试进行置信度为95%时两种蛋白饲料饲养的大白鼠增重的差数区间估计和点估计。

已算得
$$\overline{x_1} = 120.17g, \overline{x_2} = 101.00g$$

$$s_{\overline{x_1} - \overline{x_2}} = 10.005$$
 $df = 17, t_{0.05} = 2.110$

其置信度为95%时两种蛋白饲料饲养的大白鼠增重的差数区间估计为:

$$L = (\overline{x_1} \ \overline{x_2}) \ t_{\alpha/2} s_{\overline{x_1}} \ \overline{x_2}$$

$$= (120.17 \ 101.00) \ 2.110 \times 10.005 = 1.94(g)$$

$$L = (\overline{x_1} - \overline{x_2}) + t_{\alpha/2} s_{\overline{x_1}} = (120.17 - 101.00) + 2.110 \times 10.005 = 40.284(g)$$

两种蛋白质饲料饲养的大白鼠增重的差数点估计为:

$$L = (\overline{x_1} - \overline{x_2}) \pm t_{\alpha/2} s_{\overline{x_1}} = (120.17 - 101.00) \pm 2.110 \times 10.005$$
$$= 19.17 \pm 21.11(g)$$

说明两种蛋白饲料饲养下大白鼠增重的差数有95%的把握落在-1.94g~40.284g的区间里。

例题 试对表4一1资料进行置信度为99%的区间估计和点估计。

已算得

$$\overline{d} = 812.5IU \cdot g^{-1},$$
 $s_{\overline{d}} = 193.13IU \cdot g^{-1}$
 $df = 7, t_{0.01} = 3.499$

于是,两种饲料饲养下动物肝脏中 维生素A含量差数的区间估计为:

$$L = \overline{d} - t_{\alpha} s_{\overline{d}}$$
= 812.5 - 3.499 × 193.13
= 136.74(IU g⁻¹)

$$L = \overline{d} + t_{\alpha/2} s_{\overline{d}}$$
= 812.5 + 3.499 × 193.13
= 1488.26(*IU* g⁻¹)

两种饲料饲养下动物肝脏中维生素A含量差数的点估计为:

$$L = \overline{d} + t_{\alpha/2} s_{\overline{d}}$$
= 812.5 ± 3.499×193.13
= 812.5 ± 675.76(*IU* g⁻¹)

说明两种饲料饲养下动物肝脏中维生素A含量差数的有99%的把握落在136.74IU·g⁻¹~148.26 IU·g⁻¹的区间里。